

1. 請比較有無normalize(rating)的差別。並說明如何normalize：

	Normalize Ratings	Ratings
Kaggle Public Score	0.85026	0.85361

把所有 rating 做標準正規化，減去平均值再除以標準差，多次實驗後發現結果沒有太大的差別，但經過正規化後訓練的收斂速度較快。

2. 比較不同的 Latent Dimension 的結果：

Latent Dimension	64	128	256	512
Kaggle Public Score	0.86434	0.85426	0.85026	0.85994

比較不同 Latent dimension 的實驗結果，當 $K = 256$ 時有最佳的表現，但差異不大。此外，對於實驗中不同 Latent dimension 在相同的設置下(batch size, epoch) 造成 overfitting 的程度不同，加入正則項可以改善 overfitting，但仍有可能造成並非得到該 Latent Dimension 最佳結果，使實驗不準確。

3. 比較有無bias的結果：

	Without bias	With Bias
Kaggle Public Score	0.88440	0.85026

加入 user bias 和 item bias 的 bias-SVD 明顯改善模型的表現，增加了一些額外因素的考慮，如 user 的喜好及 item 的特徵。

4. 請試著用DNN來解決這個問題，並且說明實做的方法(方法不限)。並比較MF和NN的結果，討論結果的差異：

Kaggle Public Score : 0.88920

將 user embedding 和 item embedding 串接，作為 DNN 的輸入。得到不差的結果，若在模型架構上多嘗試，應該還能再精進。

MF 和 DNN 都有很多參數，容易 overfitting，且這些參數含有許多隱式的語意，大量維度較難理解和解釋。


Layer (type)	Output Shape
input_55 (InputLayer)	(None, 1)
input_56 (InputLayer)	(None, 1)
embedding_60 (Embedding)	(None, 1, 256)
embedding_61 (Embedding)	(None, 1, 256)
flatten_59 (Flatten)	(None, 256)
flatten_60 (Flatten)	(None, 256)
concatenate_13 (Concatenate)	(None, 512)
dense_25 (Dense)	(None, 256)
dropout_17 (Dropout)	(None, 256)
dense_26 (Dense)	(None, 128)
dropout_18 (Dropout)	(None, 128)
dense_27 (Dense)	(None, 1)
Total params: 2,722,305	
Trainable params: 2,722,305	
Non-trainable params: 0	

5. 請試著將movie的embedding用tsne降維後，將movie category當作label來作圖：

黃色：Animation

紫色：Thriller and Horror

綠色：Comedy



6. 試著使用除了rating以外的feature, 並說明你的作法和結果，結果好壞不會影響評分：

使用題4的 DNN 模型，將 user 的 gender 和 age 直接和 User embedding、Movie embedding 串接作為輸入。Testing 時同用將 gender 及 age 作為輸入。

Kaggle Public Score : 0.87540